

Esercitazione 2: PG2

23 Ottobre 2024

1. Si consideri il dataset Iris all'interno della sashelp library:

- crearsene una copia in work rinominandolo come Import_Iris;
- nel modo più opportuno, generare un dataset che contenga le valorizzazioni distinte assunti dal campo species;
- nel modo più opportuno, generare un dataset che contenga il numero di righe rispetto ai possibili valori che il campo species possa assumere. Ad esempio, la valorizzazione Setosa del campo species contiene 50 righe;
- spiegare il funzionamento della seguente sintassi:

```
proc means data=Import_Iris nmiss;  
run;
```

- per ogni variabile numerica all'interno del dataset Import_Iris, determinare nel modo più opportuno la media che ognuna di essa possa assumere;
- come si potrebbe gestire il caso in cui una o più variabile numerica nel dataset contenga valorizzazioni a missing? (Suggerimento: per diversi punti dell'esercizio può essere comodo usare una proc sql).

2. (Shoes report) Il dataset shoes_week.csv contiene informazioni di vendita relative all'ultima settimana su diversi articoli di un noto marchio, specificati nella variabile Product. Ogni record presenta informazioni di vendita di un prodotto in un determinato negozio di una città del mondo. In particolare, le variabili presenti sono:

- Region: luogo geografico del negozio;
- Product: nome del prodotto venduto;
- Subsidiary: città del negozio in cui si vendono i prodotti specificati;
- Stores: quantità del prodotto venduto durante la settimana in quel negozio;
- Sales: prezzo di vendita del singolo prodotto espresso in dollari.

Aiutandosi con uno script Sas, svolgere i seguenti punti:

- esplorare, caricare e importare il dataset shoes_week.csv in Sas Studio nel modo più opportuno;
 - eseguire una proc contents sul dataset precedentemente importato e aiutandosi con questa costruire una tabella che contenga il nome delle variabili del dataset;
 - tramite la variabile Region, creare nel modo più opportuno due dataset, Africa_prod e Canada_prod, che contengano le tipologie di singoli prodotti venduti in Africa e Canada;
 - in base al punto precedente, stabilire se i prodotti venduti in Africa e Canada siano gli stessi;
 - in base al punto 3 e punto 4, e aiutandosi con la variabile Subsidiary, fare un ragionamento simile stabilendo se i prodotti venduti a Praga (Prague) e a Budapest (Budapest) sono i medesimi;
 - creare un flag identificativo flag_reg concatenando le prime due lettere del campo Region con le prime tre lettere del campo Subsidiary. I due termini devono essere separati dal carattere & (ad esempio, il flag_reg per Africa e Luanda corrisponderà a Af&Lua e così via);
 - stabilire se esista almeno una Subsidiary in cui il prodotto Boot è stato venduto per almeno 10 volte;
 - il campo Sales esprime il prezzo di vendita del prodotto mentre Stores il numero di prodotti venduti nella rispettiva Subsidiary. Calcolare un nuovo campo, Entry, che esprima su ogni record il guadagno per tale prodotto;
 - a seguito di nuove direttive aziendali, è necessario modificare il dataset creando una nuova colonna detta Entry_euro che contenga i valori della variabile Entry espressi in euro (in base al cambio attuale, 1 Dollaro sta a circa 0.93 Euro). Bisogna però tenere conto di alcune tassazioni per i seguenti casi:
 - per i prodotti Boot, Sandal e Slipper venduti in Canada (Canada) aggiungere un introito aggiuntivo di 250 Euro alla variabile Entry_euro;
 - per tutto il sud America (South America) aggiungere un introito aggiuntivo pari alla metà della vendita convertita in Euro;
 - per la Subsidiary di Mosca (Moscow) aggiungere 150 Euro di introiti in più sul prodotto Boot e 110 Euro per il prodotto Sandal;
 - per tutti gli altri casi, lasciare il campo Entry_euro come tale.
3. (Meteo tropicale) Il dataset Storm.xlsx contiene informazioni sui cicloni tropicali rilevate da un ufficio meteo:
- importare e caricare il dataset in work e visualizzarne le prime dieci righe (vedi il comando obs);

- fase di Data Cleaning: tenere nell'intero dataset le variabili Season, Name, MaxWindMPH che sono state ritenute più rilevanti dall'ufficio meteo per le varie indagini. Fare dei check se queste possiedano eventuali valori a missing, valutare se eliminare o sostituire le possibili righe che presentano problemi di questo tipo;
- aggiungere, in un nuovo dataset category_distribution, la variabile Wind_Level basata sulla velocità del vento in miglia orarie (variabile MaxWindMPH) secondo una scala di Beaufort semplificata:
 - Wind_Level = "Calma" se $0 \leq \text{MaxWindMPH} < 5$;
 - Wind_Level = "Brezza" se $5 \leq \text{MaxWindMPH} < 38$;
 - Wind_Level = "Vento" se $38 \leq \text{MaxWindMPH} < 61$;
 - Wind_Level = "Burrasca" se $61 \leq \text{MaxWindMPH} < 88$;
 - Wind_Level = "Tempesta" se $88 \leq \text{MaxWindMPH} < 117$;
 - Wind_Level = "Uragano" se $\text{MaxWindMPH} \geq 117$.
- rinominare il dataset creato al punto 3 con category_distribution e, per ogni tipologia di ciclone (variabile Wind_Level), determinarne la distribuzione per ogni anno (ovvero il conteggio di tipologie di ciclone) e la velocità media del vento sempre per ogni anno e per ogni tipologia di ciclone. Nominare queste due variabili con cyclone_count e avg_max_wind;
- (Approfondimento sulla proc sgplot) Provare a esplorare la seguente sintassi per ottenere reportistiche:

```
proc sgplot data = category_distribution;
  vbar Season / response = cyclone_count
  group = Wind_Level /*groupdisplay=cluster*/;
  xaxis label = "Season" grid;
  yaxis label = "Cyclone count" grid;
  title "Distribuzione dei cicloni tropicali per categoria e anno";
run;
```

Dall'output della proc sgplot, provare a commentare il risultato. Che considerazioni potrebbe fare l'ufficio meteo?

4. Si ha a disposizione un dataset chiamato transazioni_banca contenente informazioni sulle transazioni effettuate dai clienti di una banca. Le variabili sono:
 - ID: identificativo univoco del cliente (ad esempio, una sigla alfanumerica XVC001);
 - Tipo_transazione: il tipo di transazione effettuata (può essere valorizzata a "Deposito" o "Prelievo");
 - Importo: l'importo della transazione (se il campo Tipo_transazione è stato posto a "Deposito" l'importo sarà un numero reale positivo, se "Prelievo" un numero reale negativo);

- Data: la data della transazione (scegliere a piacere un opportuno formato data per la valorizzazione di tale campo). Una volta creato il dataset con almeno tre clienti, nel modo più opportuno:
 - calcolare il saldo totale per ogni cliente, considerando che il saldo iniziale di ogni cliente viene posto a 0;
 - creare un nuovo dataset che filtri solo i clienti che hanno un saldo negativo dopo aver considerato tutte le transazioni;
 - determinare la media numerica dei depositi e dei prelievi per ognuno dei clienti del dataset;
 - classificare i clienti in base al loro comportamento finanziario: "Cliente stabile" se il saldo è positivo o pari a 0, "Cliente a rischio" se il saldo è negativo. Gestire anche l'eventualità di mancate valorizzazioni.